




edição
especial



20 PERGUNTAS SOBRE **REGRESSÃO LINEAR** QUE VOCÊ DEVERIA SABER!


coleção
para bebês



Dalson Britto Figueiredo Filho
Maria do Carmo Soares de Lima



sobre este **GUIA**



Não suporta Matemática e tem pouca intimidade com Estatística? Então este guia foi feito especialmente para você. A coleção “Para bebês” apresenta os fundamentos de várias técnicas de análise de dados, incluindo métodos quantitativos, qualitativos e abordagens computacionais no R. Cada volume conta com dicas de materiais extras para te ajudar a entender melhor o assunto.


A série foi pensada para estudantes de graduação e pós-graduação em fases iniciais de treinamento.

Este livro responde a 20 perguntas sobre regressão linear, que é a técnica estatística mais utilizada em todas as áreas do conhecimento. Organizamos o conteúdo a partir de uma linguagem simples e cada questão é acompanhada de sugestões específicas de leitura para você se aprofundar no tema.


Agora aperte os cintos e vamos embarcar nessa aventura que vai revolucionar a forma como você consome e produz evidências.

Boa leitura!

Vamos nessa?



Perguntas & Respostas



1. O que é regressão linear?

A regressão linear é uma técnica estatística usada para estudar a relação entre variáveis. Na versão simples, há uma única variável independente utilizada para entender, explicar ou prever a variação de uma variável dependente. Na versão múltipla, teremos uma série de variáveis independentes que, juntas, serão usadas para modelar a variação da variável dependente. Em uma frase: quando realizamos uma regressão linear, dizemos que a relação entre as variáveis dependente e independente (s) pode ser representada por uma linha reta no espaço de dados. Para saber mais, veja: [Krueger e Lewis-Beck \(2008\)](#), [Berk \(2010\)](#), [Fredmann \(1991\)](#), [Figueiredo Filho et al \(2011\)](#) e [Chein \(2019\)](#).

2. Quando usar a regressão linear?¹

A regressão linear é usada quando queremos entender, explicar ou prever a variação de uma variável dependente com base em um conjunto de variáveis independentes. Por exemplo, imagine que você gostaria de estimar o preço de uma casa (variável dependente). Que fatores poderiam ser utilizados como explicativos? Certamente, o tamanho do imóvel seria um deles. O bairro onde a casa está localizada também pode ser um elemento importante. Assim, na perspectiva da regressão, nosso objetivo seria calcular em que medida o tamanho do imóvel (x_1) e o bairro (x_2) explicam a variação no preço da casa (y). Viu como é simples? Para saber mais, veja: [King \(1986\)](#), [McCloskey e Ziliak \(1996\)](#), [Figueiredo Filho \(2019\)](#), [Figueiredo Filho et al \(2021\)](#) e [Figueiredo Filho \(2024\)](#).

3. O que é uma variável dependente?

A variável dependente, também chamada de variável resposta, representa empiricamente o fenômeno que desejamos entender, explicar ou prever. Por exemplo, em um estudo de Nutrição, a variável dependente poderia ser o Índice de Massa Corporal (IMC) de uma pessoa. Em uma pesquisa na área de Psicologia, a variável dependente poderia ser o diagnóstico de depressão. Toda vez que o Banco Central altera a taxa de juros, muitos economistas alertam que isso impactará o consumo, que, nesse contexto, seria a variável dependente. Em termos de notação, a variável dependente é representada pela letra Y (maiúsculo) e é plotada na vertical de um gráfico, que os matemáticos chamam, de forma muito elegante, como eixo das ordenadas 😊. Para saber mais, consulte: [Fredmann \(1991\)](#), [King, Keohane e Verba \(1994\)](#), [Lewis e Linzer \(2017\)](#), [Figueiredo Filho et al \(2016\)](#), [Figueiredo Filho \(2019\)](#) e [Chein \(2019\)](#).


¹ Veja que a definição de regressão linear envolve alguns termos que podem ter notações diferentes a depender do autor.

4. O que é uma variável independente?

A variável independente, também chamada de explicativa ou preditora, é aquela que usamos para entender, explicar ou prever variável dependente. Por exemplo, voltando ao nosso exemplo de Nutrição, a variável independente poderia ser a prática de exercícios físicos. No estudo psicológico, o desemprego poderia ser utilizado como variável explicativa do diagnóstico de depressão. Na área econômica, o aumento da taxa de juros é comumente interpretado com um fator que afeta, de forma generalizada, outros indicadores de interesse. **Anote aí:** a variável independente é representada pela letra X (maiúscula) e, no gráfico, costuma vir no eixo horizontal, o das abscissas, para você que ainda não deletou da memória os ensinamentos matemáticos do segundo grau. As coisas estão ficando mais fáceis, diga a verdade? Veja esse material complementar para a gente avançar no conteúdo: [Fredmann \(1991\)](#), [Berk \(2010\)](#), [King, Keohane e Verba \(1994\)](#), [Kellstedt e Whitten \(2018\)](#) e [Chein \(2019\)](#).

5. Como representar uma relação linear em um gráfico?

Alguém já disse por aí que um gráfico vale mais do que mil palavras! Imagine então dois gráficos.



Olhe atentamente para essas duas figuras. O que você observa em relação à distribuição das bolinhas vermelhas? “Professor, depende. Se eu olhar para o gráfico da esquerda, eu vejo que as bolinhas seguem ali aproximadas, grudadinhas, meio que formando uma reta. Já o gráfico da direita mais parece o sorriso do Coringa”. Olha aí. Você tem o *feeling* correto. Uma relação linear é representada por uma linha reta no gráfico, em que os pontos estão distribuídos em torno dessa linha. Tá vendo como é intuitivo? Essa reta, que descreve a tendência nos dados, é chamada de **reta de regressão linear**. “Mas professor, isso quer dizer que, no exemplo da direita, a reta não descreve adequadamente a distribuição dos dados!” Você já está pronto para dar aula 😊. Exatamente. No gráfico da direita, se você lembra das suas aulas do ensino médio, temos uma parábola, ou seja, uma curva. Nesses casos, não é adequado utilizar a regressão linear para examinar a relação entre X e Y por um motivo muito simples: não

temos uma relação linear. Para saber mais, dá uma olhada nesse material: [Kastellec e Leoni \(2007\)](#), [Wickham e Wickham \(2016\)](#), [Kellstedt e Whitten \(2018\)](#), [Chein \(2019\)](#) e [Figueiredo Filho \(2019\)](#).

6. O que é o coeficiente de regressão?

O coeficiente de regressão mensura a **força** e a **direção** da relação entre as variáveis. Ele indica quanto a variável dependente muda quando a variável independente, ligada a tal coeficiente, aumenta em uma unidade. **Anote aí que é importante:** o coeficiente de regressão associado à variável independente indica a variação observada na variável dependente quando o X cresce em uma unidade. Vamos te mostrar uma coisa agora, mas nada de pânico! Veja aí a representação matemática de uma equação de regressão:

$$y = a + b_1x_1$$

Assim como [Dexter](#), vamos por partes. O y representa a variável dependente. Se você prestou atenção até agora, deve está pensando: *“Eita que agora minha cabeça está muito confusa: na seção 3, falou-se que a variável dependente era representada por Y (maiúsculo)”*. Veja que você já está pegando o jeito! De fato, a representação acima é feita a partir dos valores que a variável dependente pode assumir. Por isso, diferenciamos e escrevemos com letra minúscula. Por sua vez, x1 representa a variável independente (mesmo raciocínio da explicação acima para y).

Se liga:

Enquanto no ensino médio usávamos letras minúsculas para representar variáveis, agora usaremos letras maiúsculas para esse fim! Você pode consultar, por exemplo, o livro de Paul L. Meyer, **Probabilidade Aplicações à Estatística**. Então, se escrevemos X (maiúsculo) estamos nos referindo à variável. Se escrevemos x (minúsculo), nos referimos ao valor que a variável pode assumir.

Agora se segure que vem o ponto alto do amor: b1 representa o coeficiente de regressão que relaciona x1 a y. *“Professor, viajei aqui. Pode repetir?”* Vamos lá. A gente já falou que a regressão serve para mensurar a relação entre variáveis. Então, o b1, também conhecido como coeficiente de regressão, indica a magnitude e a direção de como a variável independente se relaciona com a variável dependente. Em particular, se todos os pressupostos forem devidamente respeitados, **b1 indica a variação observada em y quando x1 aumenta em uma unidade**. *“Professor, falton falar desse ‘a’ aí! Que danado é isso?”*. Tenha calma! Vamos chegar nele já já. Por enquanto, vamos dar uma lida nesse material para a gente sentir as emoções completas do modelo de regressão: [Hair et al \(2009\)](#), [Figueiredo Filho et al \(2011\)](#), [Kellstedt e Whitten \(2018\)](#), [Figueiredo Filho \(2019\)](#) e [Chein \(2019\)](#).

7. Como interpretar o coeficiente de regressão?

Um coeficiente de regressão positivo indica que, conforme a variável independente aumenta, a variável dependente também cresce. Um coeficiente negativo indica que se a variável independente aumenta, a variável dependente diminui. “Professor, o negócio tá ficando mais claro, viu?! *Algum exemplo aí para fortalecer a amizade?*”. Tome três!

Exemplo 01: Efeito da Educação no Rendimento Salarial

Contexto: Pesquisadores querem entender em que medida o nível de educação afeta os rendimentos salariais de uma população.

Variável Dependente (Y): Rendimento salarial.

Variável Independente (X): Anos de escolaridade.

Descrição: A regressão linear vai modelar a relação entre os anos de escolaridade (VI) e o rendimento salarial (VD), permitindo estimar o salário esperado com base no nível de educação. A equação da regressão poderia ser $\text{Salário} = a + \beta_1 \times \text{Escolaridade}$. **Anote aí:** toda vez que a escolaridade aumenta uma unidade, o salário vai variar β_1 unidades. Moral da história: estude!

>> Exemplo de VERDADE: Card (1999) <<

Exemplo 02: Impacto da Atividade Física no Índice de Massa Corporal

Contexto: Médicos e pesquisadores querem saber o quanto a atividade física influencia o Índice de Massa Corporal (IMC) dos pacientes.

Variável Dependente (Y): IMC

Variável Independente (X): Horas de atividade física por semana.

Descrição: A regressão linear será usada para quantificar a relação entre o tempo gasto em atividades físicas e o IMC. A equação da regressão poderia ser $\text{IMC} = a - \beta_1 \times$

Exercícios. Anote aí: toda vez que a quantidade de exercícios aumenta uma unidade, o IMC vai variar β_1 unidades. Observe que agora temos um sinal negativo na frente do coeficiente, que representa a direção esperada entre a VI e a VD. Moral da história: se matricula na academia se o objetivo é perder peso 😊!

>> Exemplo de VERDADE: Medina et al (2010) <<

Exemplo 03: Efeito da Temperatura na Resistência de um Material

Contexto: Engenheiros podem investigar se temperatura afeta a resistência de um material específico.

Variável Dependente (Y): Resistência do material.

Variável Independente (X): Temperatura.

Descrição: A regressão linear vai modelar a relação entre a temperatura (VI) e a resistência do material (VD), ajudando a estimar em que medida mudanças na temperatura afetam a resistência. A equação da regressão poderia ser **resistência = $a + \beta_1 \times \text{Temperatura}$** .


Anote aí: toda vez que a temperatura aumenta em uma unidade, a resistência vai variar β_1 unidades. Moral da história: evite esquentar demais seus materiais eletrônicos porque pode “dar ruim”!

>> Exemplo de VERDADE: Pinheiro e Holanda (2010) <<

8. O que é o intercepto?

O intercepto é um componente essencial na modelagem de relações lineares, fornecendo um ponto de referência para entender como a variável dependente se comporta em relação à variável independente. “Professor, falou bonito, mas falou grego”. Vamos novamente! O intercepto é o ponto onde a linha de regressão cruza o eixo vertical (eixo y) em um gráfico. Ele representa o valor da variável dependente quando a variável independente é igual a zero. Vejamos isso graficamente.





Imagine que estamos tentando entender em que medida a quantidade de horas de estudo (x) afeta a nota de um aluno em uma prova (y). Para isso, utilizamos o modelo de regressão linear. O intercepto é o valor inicial da nota que o modelo prevê quando a variável independente (neste caso, as horas de estudo) é zero. Em termos substantivos, ele nos dá uma ideia de qual seria a nota esperada de um aluno que não estudou nada. Felizmente, esse não é o seu caso 😊. Esse ponto é crucial porque estabelece a base da linha de regressão, permitindo que possamos ver claramente como as notas aumentam à medida que o tempo de estudo aumenta. **Anote aí** essas dicas:

- a) Na maior parte dos casos práticos você ou não vai querer ou não vai precisar interpretar o intercepto;
- b) O modelo de regressão linear sem intercepto é útil quando há uma boa razão teórica para acreditar que a relação entre as variáveis deve passar pela origem (0 no eixo x e 0 no eixo y).

9. Como interpretar o intercepto?

Acho que já respondemos essa pergunta na seção 8, mas não custa nada repetir, não é? O intercepto representa o valor inicial da variável dependente quando todas as variáveis independentes são zero. Por exemplo, em um modelo de regressão linear que estima o preço das casas com base na área, o intercepto seria o preço base de uma casa com área zero (o que não é realista, é apenas uma convenção estatística). Um procedimento muito utilizado é centralizar a variável independente na média. Ou seja, para cada observação da planilha eu vou lá subtrair a média da distribuição daquela variável. Voltando ao nosso exemplo de prever o preço de casas a partir da área, com a variável centralizada, o intercepto vai indicar o preço esperado de uma casa

que tem que tamanho? Me ajude!!!! E a resposta é: tamanho médio. Lembrando que a inclinação da reta (b_1) não é afetada pela centralização. Como agora você tá pegando o jeito, vamos te indicar leituras mais avançadas. Ver: [Craig, Moore e McCabe \(2017\)](#), [Triola \(2017\)](#), [Kellstedt e Whitten \(2018\)](#), [Figueiredo Filho \(2019\)](#) e [Chein \(2019\)](#).

10. O que é o erro padrão da estimativa?

O erro padrão da estimativa é uma medida de dispersão dos pontos de dados em relação à linha de regressão. Indica quanto os valores observados podem variar em relação aos valores previstos pela linha de regressão que foi ajustada pelo conjunto de variáveis independentes que incluímos no modelo. Uma forma mais simples de interpretar o erro padrão da estimativa do coeficiente de regressão é compreendê-lo como um indicador de precisão. Quanto menor, melhor, pois a medida de influência de x sobre y é mais precisa. **Anote aí** essa regra de bolo: se o erro padrão é do mesmo tamanho do coeficiente de regressão, o resultado não é estatisticamente significativo. Se o erro padrão é maior do que o coeficiente de regressão, aí que danou-se tudo de vez e com toda certeza do mundo o coeficiente de regressão não será significativo dentro dos níveis usualmente utilizados (1%, 5% e 10%). Na seção do “Purgatório Matemático” a gente mostra a notação algébrica. Para saber mais, veja: [King \(1986\)](#), [McCloskey e Ziliak \(1996\)](#), [Altman e Bland \(2005\)](#), [Triola \(2017\)](#) e [Wooldridge \(2023\)](#).

11. O que é e como interpretar o coeficiente de determinação (R^2)?

O coeficiente de determinação, o famoso R^2 , é uma medida estatística usada para avaliar a qualidade do ajuste do modelo de regressão aos dados. A interpretação típica que você vai encontrar em manuais é a seguinte: ele indica a proporção da variabilidade da variável dependente que é explicada pela variável (ou variáveis) independente (s) no modelo. Esta medida varia de 0 a 1, em que 0 indica nenhum ajuste e 1 indica um ajuste perfeito. Para saber mais, veja: [Barrett \(1974\)](#), [Blomquist \(1980\)](#), [King \(1986\)](#), [Bucchianico \(2008\)](#), e [Figueiredo Filho, Silva Júnior e Rocha \(2011\)](#). Já ouviu aquela frase “quem avisa amigo é”? Veja algumas das limitações do R^2 antes de você ficar muito íntimo dele.

CUIDADOS COM O R^2 !

1. **Não indica causalidade:** um R^2 alto não implica que a relação entre as variáveis independentes e a variável dependente é causal. Podemos estar diante de uma correlação espúria ou sob a influência de variáveis de confusão não incluídas no modelo. Se você não está totalmente confortável com o conceito de correlação, veja [Figueiredo Filho e Silva Junior \(2009\)](#) e [Figueiredo Filho \(2024\)](#).
2. **Sensível a Outliers:** assim como quase tudo em análise de dados, o R^2 é significativamente afetado por casos aberrantes, que são valores anômalos nos dados. Esses pontos extremos podem distorcer a medida do ajuste do modelo (ver item 15). Se você não está totalmente confortável com o conceito de *outliers*, veja [Figueiredo Filho et al \(2023\)](#).


3. **Apenas para modelos lineares:** o R^2 apenas é interpretável para modelos lineares, sejam eles simples ou de regressão múltipla. Para modelos não lineares ou outros tipos de modelos (como logísticos), desaconselhamos o uso do coeficiente de determinação. Existem algumas estimativas, chamadas de pseudo R^2 , mas isso é conversa para outro momento. Para saber mais, veja: [Hair et al \(2009\)](#) e [Pampel \(2020\)](#).
4. **Não penaliza *overfitting*:** o R^2 é uma estatística gulosa, como diria o professor Jorge Alexandre da UFMG. Ou seja, sempre que incluímos uma nova variável no modelo, o coeficiente de determinação tende a aumentar, mesmo que essa variável não seja relevante para explicar o fenômeno de interesse. Então veja que perigo. Isso pode levar ao *overfitting*, onde o modelo se ajusta muito bem aos dados da amostra, mas não generaliza bem para novos dados. Tem uma outra estimativa, chamada de R^2 ajustado, que resolve esse problema, mas vamos ver isso em outro momento. Beleza? Ver: [King \(1986\)](#).
5. **Não reflete a qualidade do modelo:** o R^2 alto não garante que o modelo que foi ajustado aos dados é o melhor ou o mais teoricamente adequado. Pode haver modelos alternativos com diferentes variáveis independentes com maior capacidade explicativa. E, como o coeficiente de determinação não penaliza pelo excesso de variáveis, um modelo com muitos fatores explicativos vai acabar produzindo um R^2 alto, independentemente da relevância das variáveis selecionadas. Ver: [Barrett \(1974\)](#), [Blomquist \(1980\)](#) e [King \(1986\)](#).
6. **Ignora a dimensão temporal e/ou espacial:** em análises de séries temporais ou dados espaciais, o R^2 não leva em conta a autocorrelação entre observações consecutivas ou espacialmente próximas. Dessa forma, podemos ter um alto coeficiente de determinação, mas de um modelo com graves erros de especificação. Ver [King \(1986\)](#) e [Figueiredo Filho, Silva Júnior e Rocha \(2011\)](#).
7. **Não informa a importância individual de cada variável do modelo:** o R^2 fornece uma medida global do ajuste do modelo, mas não indica a relevância de variáveis independentes individuais na maior parte dos desenhos de pesquisa. Estamos interessados na direção e na magnitude de variáveis individuais, e não na capacidade de ajuste geral do modelo. Veja: [King \(1986\)](#).

12. Como interpretar o coeficiente de determinação?

Um R^2 próximo de 1 indica que o modelo de regressão explica uma grande parte da variação na variável dependente. Um R^2 próximo de 0 indica que o modelo não explica muito da variação na variável dependente. Cuidado: como já explicamos, é possível que o R^2 seja alto, mas isso não significa que o modelo esteja bem ajustado. Devemos observar se os pressupostos do modelo de regressão foram devidamente respeitados e se o modelo foi especificado corretamente em termos de variáveis de interesse e de controle. Não esqueça de consumir a literatura mais avançada sobre o tema: [Barrett \(1974\)](#), [Blomquist \(1980\)](#), [King \(1986\)](#), [Bucchianico \(2008\)](#) e [Figueiredo Filho, Silva Júnior e Rocha \(2011\)](#).

13. O que é a linha reta de melhor ajuste?

A reta de melhor ajuste, também conhecida como reta de regressão, é aquela que minimiza a soma dos quadrados das distâncias entre os pontos de dados e a própria linha. “Professor, linguagem humana, por favor!”. Esta linha representa a relação entre duas variáveis e reduz, ao máximo, as diferenças entre os valores observados e os valores preditos pelo modelo linear. A técnica mais comum para calcular essa linha é o método dos mínimos quadrados, que determina os coeficientes “a” e “b1”. “E como ver isso professor? Tem como mostrar um exemplo aí?” Claro, veja a figura abaixo.




Esta figura mostra o ajuste de um modelo de regressão linear para explicar variação de y a partir de x . O resíduo é essa distância entre cada observação e a reta. Fácil, não? E agora temos a parte mais importante: como “a” e “b1” foram calculados minimizando as distâncias entre os valores observados e os valores preditos pelo modelo, temos certeza que estamos diante da melhor representação da relação entre x e y , pois é aquela que exibe a menor quantidade de erro possível. E é por isso que o modelo se chama de regressão linear de MÍNIMOS quadrados ordinários (MQO). Nos livros em inglês você deve ter visto a terminologia OLS de *ordinary least squares*. Se liga nessas recomendações mais avançadas: [Paula \(2004\)](#), [Kennedy \(2008\)](#), [Gujarati \(2008\)](#), [Kellstedt e Whitten \(2018\)](#) e [Chein \(2019\)](#).

14. Como a regressão linear é diferente da correlação?

A regressão linear é usada para estimar o valor da variável dependente com base em uma ou mais variáveis independentes, enquanto a correlação mede apenas a força e a direção da relação entre duas variáveis, sem prever uma em termos da outra. Como já dissemos no volume sobre [Correlação de Pearson](#), “lembre-se de um dos principais mantras da ciência: **“correlação não implica causalidade”**. Portanto, devemos ser cautelosos ao inferir uma relação de causa e efeito a partir de uma correlação. **Anote aí** para não esquecer: toda causalidade pressupõe uma associação entre X e Y, mas nem toda associação implica que X cause Y. Precisamos ficar atentos às variáveis de confusão. Muitas vezes, duas variáveis são correlacionadas porque compartilham a mesma causa. Em outras, a correlação pode ser pura coincidência. Então, não esqueça: correlação não implica causalidade” (Figueiredo Filho, 2024: 8). Ver: [Hair et al \(2009\)](#), [Figueiredo Filho et al \(2011\)](#), [Kellstedt e Whitten \(2018\)](#), [Chein \(2019\)](#) e [Figueiredo Filho \(2024\)](#).

15. O que é a suposição de linearidade na regressão linear?

O pressuposto de linearidade exige que a relação entre as variáveis seja aproximadamente linear. Ou seja, os pontos de dados devem seguir uma tendência linear. Tecnicamente, a melhor forma de testar essa suposição é examinar o gráfico de dispersão entre as variáveis. Talvez um exemplo nos ajude:



Essa figura ilustra um dos gráficos mais famosos da Estatística: o quarteto de [Anscombe \(1973\)](#). Observe que, tanto no exemplo 1 quanto no exemplo 3, é possível representar a relação entre as variáveis a partir de uma reta. Diferentemente, no exemplo 2, a forma mais adequada de

representar a relação entre x_2 e y_2 é a partir de uma curva. Neste caso, temos uma violação do pressuposto da linearidade e o modelo de regressão não será a forma mais adequada de quantificar a relação entre as variáveis. A essa altura você já deve ter entendido a razão disso. Como é que eu vou descrever com uma reta uma relação que é melhor representada por uma curva? Exatamente. Fica ruim. Claro que existem outros detalhes e algumas coisas mais avançadas, mas por enquanto acreditamos que já está de bom tamanho para você compreender o básico. “Professor, faltou falar sobre o exemplo 4”. Vixe Maria, tem razão. O exemplo 4 é ainda mais estranho. Observe que não existe relação entre as variáveis, o que temos aqui é uma correlação espúria causada por um *outlier*. Moral da história: sempre examine graficamente a relação entre as variáveis de interesse antes de ajustar qualquer tipo de modelo. Vamos ler mais? Ver: [Hair et al \(2009\)](#), [Figueiredo Filho et al \(2011\)](#), [Kellstedt e Whitten \(2018\)](#), [Chein \(2019\)](#) e [Figueiredo Filho \(2024\)](#).

16. O que é o pressuposto de independência dos resíduos?


A suposição de independência dos resíduos sugere que os resíduos (diferenças entre os valores observados e os valores previstos pela linha de regressão) não devem estar relacionados entre si. “Sim, professor, traduza aí em linguagem de seres humanos pelo amor do Criador!”. O pressuposto de independência dos resíduos é uma regra importante em modelos de regressão linear e outros modelos estatísticos. Ela significa que os resíduos, que são as diferenças entre os valores observados e os valores previstos pelo modelo, devem ser independentes uns dos outros. Em outras palavras, o valor do erro em uma observação não deve influenciar ou estar relacionado com o valor do erro em outra observação. Por exemplo, imagine um estudo que procura prever o nível diário de chuvas a partir de dados históricos, uma série temporal. Como estamos lidando com informações sequenciais (mensurações dia a dia), a quantidade de chuva em dias consecutivos tende a estar correlacionada com a variável tempo. É o que os Estatísticos chamam, de forma muito elegante, de correlação serial de dados. **Anote aí** essas dicas:

- a) uma forma eficaz de examinar a independência dos resíduos é com o auxílio de um gráfico que compara os valores previstos com os erros do modelo (resíduos). A expectativa teórica é que a maior parte dos pontos esteja ao redor de zero, sem nenhum padrão aparente. Por outro lado, se for possível detectar algum padrão, como uma curva ou uma sequência de pontos ascendentes ou descendentes, isso indica dependência entre os resíduos;
- b) para dados longitudinais, o teste Durbin-Watson pode ser empregado para verificar se há correlação entre resíduos consecutivos em uma série temporal. Valores próximos de 2 indicam independência, enquanto valores muito baixos ou muito altos sugerem autocorrelação.

“Professor, gostei desse negócio de resíduos. Quero saber mais sobre esse tema”. Ótimo. Veja esse quinteto aqui: [Berry \(1993\)](#), [Cook \(1998\)](#), [Weisberg \(2005\)](#), [Hair et al \(2009\)](#) e [Fox \(2019\)](#).


17. O que é o pressuposto de homocedasticidade?

A primeira vez que eu ouvi essa palavra foi em um curso de introdução à estatística ministrado pelo professor Jorge Alexandre da UFMG. Na ocasião, confesso que não vou mentir, mal consegui pronunciar a palavra sem gaguejar. Vou te ensinar da mesma forma que ele me ensinou. Vamos separar a palavra ao meio: “homo”, que significa mesmo e “cedasticidade”, que significa variação. Agora junte as duas: mesma variação. *“Variação de que, professor, pela misericórdia?”* Mesma variação dos resíduos. O pressuposto de homocedasticidade é uma das suposições fundamentais em modelos de regressão linear e outros modelos estatísticos. Ele se refere à condição em que a variabilidade dos resíduos (ou erros) é constante ao longo de todos os níveis da variável independente. Em particular, homocedasticidade significa que os resíduos de um modelo de regressão têm variância constante para todos os valores da variável independente. Tecnicamente, quando você plota os resíduos do modelo contra os valores previstos (ou contra a variável independente), um padrão homocedástico mostrará uma distribuição dos resíduos que parece aleatória e uniforme, sem formar padrões. Vamos fazer o seguinte. Vamos ver uma comparação de um resíduo homocedástico versus um resíduo que viola esse pressuposto, o qual chamamos de heterocedástico (hetero de diferente, né?).



Observe que no gráfico da esquerda, que respeita o pressuposto da homocedasticidade, os resíduos ficam ali pairando ao redor do zero. Alguns pontos acima, outros abaixo, mas nada de muito relevante. Padrão diferente dos resíduos heterocedásticos, que começam ali acanhados, mas à medida que o X aumenta, a variância vai ficando maior, conforme mostra o gráfico da direita. Veja como os pontos vão, de forma gradativa, ficando mais distantes do zero. Dado os propósitos deste manual, não vamos te explicar matematicamente porque isso ocorre. Você tem que acreditar

e pronto! Tal qual você acredita no teorema de pitágoras² e no teorema do limite central³. Por enquanto, “aceita que dói menos 😊”. Vejamos agora outro exemplo que compara um resíduo bem comportado, como se diz por aí, e um resíduo totalmente fora da casinha, invenção nossa, :).



O gráfico da esquerda mostra os pontos variando em torno do zero, um pouco acima da linha, um pouco abaixo. Mas veja que não existe nenhum caso destoante, não temos nenhum padrão identificável. Veja agora o gráfico da direita. Claramente temos um comportamento curvilíneo, em que seria possível ajustar uma parábola. Estamos diante de resíduos heteroscedásticos, o que é uma violação ao bom funcionamento do modelo de regressão. O principal problema de modelos com esse tipo de resíduo é que os testes de significância serão inconsistentes, ou seja, não poderemos confiar no p-valor e no intervalo de confiança da estimativa. Felizmente, existem formas de corrigir esse problema, como transformações logarítmicas e regressão linear ponderada, mas isso é cena dos próximos capítulos. Por ora, você deve saber que a homocedasticidade é um pressuposto importante e que devemos verificar em que medida ele foi respeitado antes de

² O Teorema de Pitágoras é um princípio fundamental da geometria, especificamente aplicável a triângulos retângulos, ou seja, triângulos que possuem um ângulo reto (90 graus). Para um triângulo retângulo, o Teorema de Pitágoras afirma que:

$$a^2 + b^2 = c^2$$

Em que: a e b são os comprimentos dos catetos (os dois lados que formam o ângulo reto), c é o comprimento da hipotenusa (o lado oposto ao ângulo reto, que é o lado mais longo do triângulo). O teorema nos diz que a soma dos quadrados dos comprimentos dos catetos é igual ao quadrado do comprimento da hipotenusa.

³ O Teorema do Limite Central (TLC) é um conceito fundamental na teoria da probabilidade e na estatística. Ele descreve o comportamento da média de amostras de uma população à medida que o tamanho da amostra aumenta. O Teorema do Limite Central afirma que, sob certas condições, a distribuição da soma (ou média) de um grande número de variáveis aleatórias independentes e identicamente distribuídas tende a se aproximar de uma distribuição normal (ou distribuição gaussiana), independentemente da forma da distribuição original das variáveis.

interpretar os resultados. Estamos conversados? “Vai que é tua Tafarel!” e dá um olhada nesses trabalhos aqui: [Berry \(1993\)](#), [Cook \(1998\)](#), [Weisberg \(2005\)](#), [Hair et al \(2009\)](#) e [Fox \(2019\)](#).

18. O que é o pressuposto da normalidade dos resíduos?

Anote aí porque é importante: a suposição de normalidade dos resíduos significa que a diferença entre os valores observados e os valores preditos pelo modelo é distribuída normalmente. Em outras palavras, se você coletar os resíduos de um modelo estatístico e fizer um gráfico de frequência (como um histograma), a forma deve se parecer com uma curva normal (ou curva de sino). “Sim, mas por que isso é importante?”. O modelo de regressão, assim como uma receita de um bom bolo de noiva, deve seguir algumas regras para que os resultados sejam confiáveis (o vinho, por exemplo, não pode ser qualquer um num bolo de noiva). O pressuposto da normalidade dos resíduos é um pré-requisito para o cálculo das estatísticas t e F, por exemplo, que por sua vez serão utilizadas para aferir a significância estatística das variáveis incluídas no modelo e para construção do intervalo de confiança das estimativas. *“Professor, o negócio tá azedando rápido! Um monte de conceito estranho aparecendo aí”*. Pois é. Dada as limitações deste documento e nossos objetivos, vamos parar por aqui. Por ora, você tem que saber que a normalidade dos resíduos é um pressuposto importante e que deve ser respeitado na hora de estimar o modelo de regressão linear. Tá contigo: [Berry \(1993\)](#), [Cook \(1998\)](#), [Weisberg \(2005\)](#), [Hair et al \(2009\)](#) e [Fox \(2019\)](#).

19. O que é a multicolinearidade na regressão linear?

A multicolinearidade ocorre quando duas ou mais variáveis independentes em um modelo de regressão estão altamente correlacionadas entre si. O principal efeito de altos níveis de correlação entre as variáveis explicativas é a ineficiência das estimativas. A multicolinearidade tende a aumentar os erros padrão dos coeficientes de regressão, comprometendo a confiabilidade dos testes de significância (valores p e intervalos de confiança). Como resultado, os valores p tendem a ser maiores e os intervalos de confiança menos precisos. Isso ocorre porque, na presença de variáveis altamente colineares, há menos informação disponível para calcular o efeito individual de cada variável independente sobre a variável dependente. Consequentemente, menos informação leva a uma maior variação, resultando em menor precisão. Em geral, os coeficientes permanecem não-viesados, mas perdem a eficiência (menor variância possível). Além disso, altos níveis de correlação entre as variáveis independentes podem resultar em um modelo em que a maioria dos coeficientes não é significativa, embora apresente um alto coeficiente de determinação (R^2), o que não faz sentido do ponto de vista substantivo.

Outro problema causado por variáveis independentes colineares é a instabilidade dos coeficientes. A inclusão ou exclusão de um único caso, ou o acréscimo de uma nova variável, pode alterar dramaticamente a magnitude e a direção dos coeficientes. A maneira mais simples de detectar a multicolinearidade é estimar uma matriz de correlação entre as variáveis independentes.

Quanto maior a magnitude dos coeficientes, maiores são os potenciais problemas. A literatura sugere que um coeficiente de correlação de 0,9, independentemente do sinal, é um parâmetro

crítico. Outra abordagem é tratar cada variável independente como uma variável dependente e estimar um modelo explicativo com as demais variáveis independentes. Quanto maior o coeficiente de determinação resultante, mais severos são os problemas de multicolinearidade. Tecnicamente, a literatura recomenda duas medidas sínteses para diagnosticar problemas de colinearidade: (1) Tolerância e (2) Fator de Inflação da Variância

(*Variance Inflation Factor – VIF*). Para saber mais, veja: [Hair et al \(2009\)](#), [Figueiredo Filho et al \(2011\)](#), [Figueiredo Filho, Silva e Domingos \(2015\)](#), [Kellstedt e Whitten \(2018\)](#) e [Chein \(2019\)](#).

20. Como avaliar a qualidade do ajuste de um modelo de regressão linear?

A qualidade de um modelo de regressão linear pode ser avaliada com auxílio de medidas como o R^2 , AIC, o erro padrão da estimativa, a análise dos resíduos e a validação cruzada. Essas medidas ajudam a determinar o quão bem o modelo se ajusta aos dados e se suas suposições foram atendidas. Para os nossos propósitos, **anote aí** essa lista:

- 1) **R^2 e R^2 ajustado:** Avaliam a proporção da variância explicada;
- 2) **Análise de Resíduos:** Verifica a distribuição e padrões dos resíduos;
- 3) **Erro Padrão da Estimativa:** Mensura a precisão das previsões;
- 4) **Testes de Significância:** Examina os valores p e intervalos de confiança dos coeficientes;
- 5) **CrITÉrios de Informação:** Mede a bondade do ajuste através do AIC e BIC, por exemplo, para comparação de modelos;
- 6) **Multicolinearidade:** Verifica os VIFs para detectar correlações entre variáveis independentes;
- 7) **Diagnóstico de Influência:** Identifique pontos de dados com alta influência;
- 8) **Validação Cruzada:** Avalie a capacidade de generalização do modelo e
- 9) **Análise Gráfica:** Utilize gráficos para avaliar a adequação dos pressupostos do modelo.

Essas métricas e técnicas, quando usadas em conjunto, serão ferramentas úteis na hora de aferir a qualidade do ajuste de um modelo de regressão linear, ajudando a identificar pontos fortes e fraquezas do modelo. Veja: [Berry \(1993\)](#), [Cook \(1998\)](#), [Weisberg \(2005\)](#), [Hair et al \(2009\)](#) e [Fox \(2019\)](#).



Recomendações Finais





Agora que você já entendeu o básico, vamos recomendar alguns conteúdos para você se transformar em um Pokémon Megazord!

- a)** Procure, no Coursera e Edx, cursos diretamente relacionados com regressão, análise de dados e programação (em R ou Python);
- i) *“Professor, mas existem muitos cursos nessas plataformas! Qual devo fazer?”*. Nossa recomendação é qualquer um. Isso mesmo. Qualquer um desses cursos serão úteis ao seu desenvolvimento como analista de dados. [Esse](#) e [esse](#), por exemplo, são muito bem avaliados!
- b)** Se não conhece as linguagens de programação acima, comece lendo alguns materiais como, por exemplo, [Landeiro-Introducao.pdf \(r-project.org\)](#) (para o caso do R). Outro livro muito bacana para começar a estudar é o [R Statistical foi escrito pelo professor Jakson Aquino da Universidade Federal do Ceará \(UFC\)](#). Se sua praia é algo mais mercado, você pode fazer alguns cursos gratuitos de Python. Recomendamos [esse](#), [esse](#). Para o curso inicial sobre o R, recomendamos esse.
- c)** Uma coisa que ajuda muito a aprofundar os conhecimentos é participar de cursos de verão. Vamos deixar aqui uma lista de algumas escolas importantes na área de Ciências Sociais, mas você encontra fácil na internet intensivos de outras áreas.
- ii) Nossa primeira recomendação é o tradicional curso de métodos quantitativos da UFMG, o famoso MQ. Vale cada centavo: <https://www.fafich.ufmg.br/~mq/>.
- iii) Outro curso intensivo muito banca é o summer school da IPSA, que ocorre anualmente na USP. Excelente qualidade, porém um pouco mais salgado em termos financeiros. Afinal, estamos falando de São Paulo. Mas, se tiver condições, vá. Eles também ofertam bolsas!: [https://www.ipsa.org/summer-school/sao-paulo](https://www.ipsa.org/summer-school/sao-paulo;);
- >> [Se liga que tem alguns cursos disponíveis online](#) <<
- iv) Mais recentemente, o IESP começou a ofertar um curso de inverno muito bacana com ênfase em métodos de pesquisa. Muita gente boa por lá e tem a vantagem de ser no Rio de Janeiro, fala sério né! <https://inverno.iesp.uerj.br/>.
- v) E não é que existe uma escola de métodos também no Centro-Oeste? Se organizar direitinho, você faz os cursos lá na UNB, depois vai conhecer a Chapada dos Veadeiros e, pelo amor do divino, prove a galinhada com pequi: <https://www.metodosipol.com/inscri%C3%A7%C3%A3o>
- vi) Por fim, tem a escola da FGV, que os paulistas chamam, com intimidade, de GV: <https://escola-metodos-quantitativos.fgv.br/disciplinas-2024>

- d) Já fez curso online, já leu os trabalhos básicos de R, já fez o curso de verão. E agora? O que mais devo fazer? Vamos agora estudar outras técnicas estatísticas como correlação, regressão logística, análise fatorial, análise de correspondência, análise de *cluster*, séries temporais, econometria com foco em avaliação de impacto, análise de conteúdo, revisão sistemática e meta-análise e métodos mistos (*sim, isso é um checklist*).
- e) Estamos ficando cada vez mais profissionais. Para dar aquele diferencial, vamos também fazer os cursos do [BITSS](https://www.bitss.org/education/) sobre transparência e replicabilidade.
vii) <https://www.bitss.org/education/>
- viii) Posso te contar um segredo? Você jura que fica entre nós? Todo ano eles têm uma chamada para um curso presencial na Califórnia com tudo pago (hotel, traslado e alimentação). Agora pense comigo: quem será que tem mais chance de ser aceito, uma pessoa que não sabe nada de transparência e integridade científica ou alguém que já completou o curso sobre o assunto?
- f) Junte tudo isso e comece a aplicar na sua área específica de estudos. Vai fazer um artigo? Use o R para fazer alguma coisa. Vai tabular uma base de dados? Procura uma ferramenta computacional que possa facilitar o processo. Em particular, é importante aprender a usar as ferramentas de inteligência artificial. Elas chegaram para ficar! Por exemplo, para revisão de literatura, você pode ir para a biblioteca como faziam os Astecas OU aprender a usar o [Google Scholar](#), [Publish or Perish](#) e [Litmaps](#).

Pronto! Se você seguir atentamente estas dicas, não temos mais nada para te ensinar. Esperamos que este documento te ajude a extrair o máximo de conhecimento possível da sua pós-graduação. Ps. Se encontrar o professor ou a professora por aí, bem que você poderia nos convidar para um café, uma cerveja ou um sorvete! :) Até a próxima!





Purgatório Matemático





1 PURGATÓRIO MATEMÁTICO

Vamos deixar aqui algumas notações mais técnicas para você começar a se familiarizar com a forma de representar matematicamente esses conceitos. Lembre-se que a matemática nada mais é do que uma linguagem. Então, no começo pode ser um pouco complicado, mas com o tempo você vai pegando o jeito. Em particular, estamos interessados em cinco elementos básicos do vocabulário da regressão linear:

- Coeficiente de regressão: b_1 ;
- Erro padrão da estimativa: S_e ;
- Coeficiente de determinação: R^2 ;
- Critério de Informação de Akaike: AIC;
- Resíduos.

1. Coeficiente de regressão (b_1) é o termo ligado à variável independente no modelo de regressão (veja a equação disposta na resposta à pergunta 6).

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

em que

b_1 é o coeficiente de inclinação da reta de regressão;

x_i é o valor da variável independente para a i -ésima observação;

y_i é o valor da variável dependente para a i -ésima observação;

$\bar{x}$ é a média dos valores da variável independente;

$\bar{y}$ é a média dos valores da variável dependente;

n representa o número de observações (tamanho da amostra).

2. O erro padrão da estimativa (ou erro padrão residual) é a raiz quadrada da média dos quadrados dos resíduos (diferenças entre os valores observados e os valores previstos). Matematicamente, é dado por:

$$S_e = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}},$$

em que

S_e é o erro padrão da estimativa;

y_i é o valor da variável dependente para a i -ésima observação;

$\hat{y}_i$ são os valores previstos pela linha de regressão;

n é o número de observações.

3. Coeficiente de determinação ou R quadrado é uma estatística que mede qualidade de ajuste do modelo e assume valores no intervalo $[0,1]$ de tal forma que valores próximos de 1 indicam um melhor ajuste. Se liga: o cálculo é realizado pela diferença entre 1 e o quociente entre a variância residual e a variância da variável dependente. Matematicamente, pode ser obtido através da fórmula

$$R^2 = 1 - \frac{\sigma_r^2}{\sigma^2} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

em que

R^2 é o coeficiente de determinação;

σ_r^2 é a variância do resíduo;

σ^2 é a variância da variável dependente Y ;

y_i é o valor da variável dependente Y para a observação i ;

$\hat{y}_i$ é o valor aproximado pelo modelo de regressão para a observação i ;

$\bar{y}$ é a média da variável dependente em todas as observações.

4. Critério de Informação de Akaike (ou Akaike Information Criterion, do inglês) é uma medida estatística de qualidade de ajuste que leva em conta a simplicidade do modelo. Quanto menor for o valor do AIC, melhor será o ajuste. Matematicamente, calculamos o AIC como segue

$$\text{AIC} = 2k - \ln(\hat{L}),$$

em que


k é o número de parâmetros. No caso da regressão linear simples (tratada na fórmula da pergunta 6), onde temos apenas uma variável independente, faremos $k = 2 + 1 = 3$. Já que o valor padrão para k é 2, basta somar a esse número a quantidade de variáveis independentes do modelo; $\ln(\hat{L})$ é a probabilidade logarítmica do modelo.

“Eita professor, agora complicou foi tudo!” Calma! A maioria dos softwares estatísticos calcula isso para você.

5. Resíduos consistem na diferença entre os valores observados e os ajustados. Lembre-se: o objetivo da regressão linear é medir a relação entre

a(s) variável(is) explicativa(s) e a variável resposta e, para fazer isso, a regressão linear tentar encontrar a reta que “melhor” se ajusta aos dados. Como a reta provavelmente não vai capturar exatamente os dados observados, a reta vai produzir apenas uma previsão. Então, essa diferença entre a previsão e o valor observado é o que chamamos de resíduo. Matematicamente, temos

$$\text{Resíduos} = \text{Valor observado} - \text{Valor ajustado}$$





Sobre o Autor

Dalson Figueiredo é torcedor do glorioso Sport Clube Recife, campeão da Copa do Brasil de 2008. Pai de Rudá Alquete Figueiredo, Dalson atualmente é professor Associado do Departamento de Ciência Política da Universidade Federal de Pernambuco (UFPE) e Catalisador do Berkeley Initiative for Transparency in the Social Sciences (BITSS).

Em 2023, assumiu a coordenação do Programa de Pós-Graduação em Ciência Política da UFPE e hoje atua como Coordenador Científico do Mestrado Profissional em Políticas Públicas (MPPP/UFPE). Em 2022, foi pesquisador visitante na Universidade de Oxford, Reino Unido. Foi também bolsista do Summer Program in Social Science (2015-2017) e do Teaching Integrity in Empirical Research (TIER), Haverford College (2016-2017). Em 2018 foi pesquisador visitante na Universidade de Nottingham, Reino Unido.

Doutor em Ciência Política pela Universidade Federal de Pernambuco em 2012 com uma tese sobre gastos de campanha, pobreza e resultados eleitorais. Foi pesquisador visitante na Universidade de Indiana (Bloomington, 2014), na William Mitchell College of Law (Saint Paul, 2011) e na Universidade de Wisconsin (Madison, 2009). Finalizou o mestrado em Ciência Política na UFPE em 2009 com uma dissertação sobre grupos de interesse, financiamento de campanha e regulação eleitoral. Em 2005, recebeu o título de bacharel em Ciências Sociais pela UFPE, com período sanduíche na Universidade do Texas (Austin, 2003).

Atua principalmente nas áreas de métodos de pesquisa e transparência científica. Tem dois livros publicados: um sobre financiamento de campanha e outro sobre métodos quantitativos em Ciência Política.



[Ei! Se quiser ganhar descontos especiais nos livros, fala diretamente comigo **no Twitter** (ninguém fala "X", fala sério!)]

Sobre a Autora

Maria do Carmo Soares de Lima é mãe de Alice, ama lecionar e cozinhar nas horas vagas. Possui graduação em Licenciatura em Matemática (2009), quando foi laureada, mestrado em Estatística (finalizado em 2012), ambos realizados na Universidade Federal de Pernambuco (UFPE).

Tem experiências nas áreas de Estatística e Matemática. Prestou serviços à UFPE como professor grau 3 substituto no departamento de Matemática. Doutora também pela UFPE (2015). Atualmente exerce o cargo de professor Adjunto Classe C na UFPE no departamento de Ciência Política, fazendo parte do corpo da pós-graduação em Estatística desta universidade, como membro permanente.

Além disso, foi vice-coordenadora do Programa da Pós-graduação de Estatística da UFPE. Foi coordenadora da pós-graduação supracitada por mais de 2 anos. Trabalha nas áreas de Probabilidade, Regressão, Análise de Sobrevida, Teoria de Novas Distribuições, Séries Temporais e NLP. Faz parte do corpo colaborador do programa de pós-graduação em Ciência Política da UFPE e atualmente é membro do Group of Engineering in Decision-Making and Artificial Intelligence (GEDAI.UFAL).

Algumas de suas principais obras são os artigos

- New exponentiated-Weibull-G family: Properties, simulations, regression and applications to COVID-19 data . DOI: 10.32372/ChJS.14-02-03;
- Analyzing county-level COVID-19 vaccination rates in Texas: A new Lindley regression mode. <https://doi.org/10.3390/covid3120122>;
- A notable Gamma-Lindley first-order autoregressive process: An application to hydrological data. <https://doi.org/10.1002/env.2724>;
- Beta regression model nonlinear in the parameters with additive measurement errors in variables. <https://doi.org/10.1371/journal.pone.0254103>

