




volume
zero



UM GUIA DESCOMPLICADO!

REGRESSÃO LINEAR

para bebês



Dalson Britto Figueiredo Filho

Autor: Dalson Britto Figueiredo Filho

Projeto Gráfico: Marília Gabriella Lira

Copyright desta edição © 2024

Todos os direitos reservados. A reprodução não autorizada desta publicação, no todo ou em parte, constitui violação de direitos autorais. (Lei 9.610/98).

À minha eterna companheira e ao fruto do nosso amor,

Não participo de jogos de loteria, pois entendo que toda sorte que alguém possa desejar na vida já me foi gentilmente concedida no momento em que Bruna optou por compartilhar a jornada da sua existência ao meu lado. Rudá é ainda mais sortudo pois vai desfrutar de tudo isso ao lado de Malala e Mandela, os nossos primeiros filhos.

PREFÁCIO

Jorge Alexandre Neves

A primeira coisa que alguém que estuda análise de regressão deve saber é que a variável dependente – ou variável resposta – regressa, ela não regride, como eu cheguei a pensar, quando comecei a estudar este assunto, no início da década de 1990. Neste livro do Prof. Dalson Figueiredo, a leitora ou o leitor aprenderão vários desses macetes (ou bizus, como falávamos na minha juventude, em Olinda).

Dalson tem feito contribuições muito importantes para a popularização dos métodos quantitativos, em particular das análises estatísticas, nas Ciências Sociais. E é um indivíduo que acredita tanto nisso tudo que, uma vez ao caçar um javaporco no interior de São Paulo e, tendo apenas duas balas em sua arma, fez os dois disparos, tendo errado ambos por meio metro de distância a cada lado do alvo, comemorou mesmo assim, pois o valor esperado era justamente a testa do suíno. Deve ter corrido bastante para não ser vitimado pelas presas do animal, mas manteve sua coerência metodológica.

Deixando as brincadeiras de lado, tenho certeza que você que me lê agora irá aprender muitas coisas úteis, que ajudarão bastante no avanço de seus conhecimentos sobre análise de regressão linear. É importante ressaltar que esta técnica de análise estatística de dados é a mais utilizada em nível global, em várias áreas científicas e profissionais, incluindo as humanidades e as Ciências Sociais em geral. Da mesma forma, é fundamental considerar que este assunto é base para a compreensão de muitas das análises estatísticas multivariadas, bem como das análises econométricas e diversas análises psicométricas. Já que você chegou neste terceiro e último parágrafo deste prefácio, tenho duas coisas finais para te dizer: você tomou uma ótima decisão ao escolher estudar regressão com o auxílio deste ebook e tenha uma ótima leitura!

Jorge é Professor titular do departamento de sociologia da Universidade Federal de Minas Gerais (UFMG), Ph.D. pela universidade de Wisconsin-Madison/EUA, pesquisador PQ-2 do CNPq, ex-diretor da FAFICH-UFMG.



sobre este GUIA

Não suporta Matemática e tem pouca intimidade com a Estatística? Então este guia foi feito especialmente para você. A coleção “Para bebês” fornece os fundamentos de várias técnicas de análise de dados. Cada volume conta com dicas de leituras mais avançadas e recomendações de materiais extras para te ajudar a entender melhor o assunto.

A série foi pensada para estudantes de graduação e pós-graduação em fases iniciais de treinamento. Para aumentar o potencial pedagógico do texto, disponibilizamos publicamente todas as bases de dados e scripts computacionais.

Este livro apresenta uma introdução prática à Regressão Linear, técnica estatística mais popular da ciência. Organizamos o conteúdo a partir de três exemplos em nível crescente de complexidade.

Agora aperte os cintos e vamos embarcar nessa aventura que vai transformar a forma como você consome e produz evidências.

Boa leitura!



Vamos nessa?



SUMÁRIO

Bora nessa que vai ser massa!

07

Perguntas e Respostas

★

Tirando as dúvidas mais frequentes sobre Progressão Linear

Script Básico

★

*Por onde eu começo?
Até onde consigo chegar?
Quais são os macetes?*

09

10

Exemplo 1

★

Ou: Os primeiros passos e técnicas para entender e descobrir tudo

Exemplo 2

★

Utilizando simulação computacional para gerar dados

12

14

Exemplo 3

★

E se eu fosse contratada para auxiliar dados sobre segurança pública?

Conclusão

★

E aí? O que consegui aprender?

16

17

Para dar aquele Pump!

★

Materiais excelentes para dar o gás nos estudos

Outras Dicas & Recursos

★

Otras cositas más!

18

Perguntas e Respostas



1. O que é regressão linear e para quê ela é usada?

A regressão linear é uma técnica estatística que permite estimar a relação entre uma variável dependente (a variável que queremos entender/explicar/prever) e uma ou mais variáveis independentes (também chamadas de variáveis explicativas).

2. Qual é a diferença entre a regressão linear simples e a regressão linear múltipla?

Na regressão linear simples temos somente uma única variável independente. Por exemplo: podemos investigar em que medida o peso (variável dependente) varia em função dos hábitos alimentares (variável independente). A regressão linear múltipla permite aumentar a complexidade da análise ao incluir duas ou mais variáveis explicativas. Para utilizar o mesmo exemplo, nosso estudo poderia tentar explicar a variação do peso em função dos hábitos alimentares, da idade e do gênero. Viu como é fácil?

3. O que é o coeficiente de determinação (R^2) em uma regressão linear?

O coeficiente de determinação, representado por R^2 , é uma medida que indica a proporção da variabilidade na variável dependente que é explicada pelas variáveis independentes no modelo de regressão. Ele varia de 0 a 1, sendo 1 indicativo de uma correspondência perfeita entre os dados e o modelo. **Cuidado: um R^2 muito alto não é necessariamente um bom sinal.** Mas um coeficiente de determinação perto de zero indica que o modelo teórico proposto não consegue explicar a variação observada na sua base de dados [vamos aprender mais sobre esse tema no volume exclusivo sobre o R^2 , beleza?]. **Bola pra frente, segue o jogo!**

4. Quais são os principais pressupostos da regressão linear?

Diferentes manuais indicam listas mais ou menos abrangentes de pressupostos que precisam ser satisfeitos para que as estimativas do modelo de regressão representem adequadamente os parâmetros populacionais. Vejamos alguns: a) linearidade, ou seja, a relação entre as variáveis deve ser linear; b) homoscedasticidade, ou seja, a variabilidade dos erros deve ser constante em todos os níveis das variáveis independentes; c) normalidade, ou seja, os erros devem

seguir uma distribuição normal e d) independência dos erros, ou seja, os erros devem ser independentes uns dos outros. Calma! Eu sei que tá parecendo grego com mandarim, mas aos poucos você vai se acostumar com a linguagem técnica da área. Por enquanto, basta saber que para funcionar, como uma receita de bolo, a regressão exige que alguns pré-requisitos sejam observados.

5. Como o modelo de regressão linear simples pode ser representado em uma equação?

Um modelo de regressão linear simples pode ser representado pela seguinte equação: $Y = a + bX$, onde Y é a variável dependente, X é a variável independente, ‘ a ’ é a constante (também chamado de intercepto) e ‘ b ’ é o coeficiente de regressão (ou inclinação da reta). Não se preocupe agora com os detalhes matemáticos!

6. Como a multicolinearidade atrapalha a regressão linear?

A multicolinearidade ocorre quando duas ou mais variáveis independentes estão altamente correlacionadas [Se você ainda não está confortável com o conceito de correlação, veja o volume *Correlação para Bebês*]. Existem dois principais remédios para superar esse problema: a) aumentar o tamanho da amostra e b) juntar as variáveis fortemente correlacionadas em uma medida sintética. Cuidado: não devemos simplesmente excluir uma das variáveis do modelo sob pena de produzir erros de especificação. Falaremos mais sobre isso em outros números da série [multicolinearidade e análise de componentes principais].

7. Como avaliar a qualidade do ajuste em um modelo de regressão linear?

O coeficiente de determinação (R^2) é usualmente empregado para avaliar a qualidade do ajuste do modelo aos dados. **Cuidado: tanto um R^2 muito alto quanto um R^2 muito baixo pode indicar eventuais problemas.** Para saber mais, ver: **King (1995) e Figueiredo Filho, Júnior e Rocha (2011)**¹. Existem outras medidas para avaliar o ajuste de modelos estatísticos como AIC, BIC, MSE, RMSE, entre outros. Veremos isso mais na frente em abordagens mais avançadas. Vamos com calma!

¹ Você pode encontrar a referência completa no tópico “Para dar aquele PUMP!”

Script Básico



```
modelo <- lm(vd ~ vi, data = base_de_dados)
summary(modelo)
```

Anote aí para não se confundir:

- # modelo representa o objeto que armazenará os resultados da função **lm**
- # lm é a função nativa do R que permite estimar a regressão linear
- # vd é a variável dependente
- # vi é a variável independente
- # data representa a base de dados

Pronto. Esses são os elementos básicos para você implementar computacionalmente um modelo de regressão no R. Vamos praticar?

EXEMPLO 01

```
m1 <- lm(mpg ~ cyl, data = mcars)
summary(m1)
```

Vejamos os resultados obtidos pela função summary(m1):

Coefficients:

	Estimate	STd. Error	t value	Pr(> t)	
(Intercept)	37.8846		2.0738	18.27	<2e-16 ***
cyl	-2.8758		0.3224	-8.92	6.11e-10 ***

Signif. codes: 0 '***' 0.01 '**' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.206 on 30 degrees of freedom
Multiple R-squared: 0.7262, AdjustedR-squared: 0.7171
F-statistic: 79.56 on 1 and 30 DF, p-value:6.113e-10

Em nosso primeiro exemplo, utilizamos uma base de dados do próprio R para estimar a relação entre a eficiência energética (mpg) e a quantidade de cilindros (cyl). “Ah professor, não tem um exemplo melhorzinho não? Algo de ciências sociais ou ciência política?”. Olha, até tem. Mas é importante você entender que essa técnica pode ser aplicada para qualquer área do conhecimento. Então, vamos começar com esse exemplo feioso e depois a gente pula para um mais legal. Blz? Vamos em frente!

Em geral, devemos olhar para três características do nosso coeficiente de regressão: a) magnitude, que indica a força da relação entre variável independente e variável dependente; b) o sinal, que indica a direção da relação (se positiva ou negativa) e c) a significância estatística, que indica em que medida os resultados da amostra podem ser generalizados para a população.

Anote que isso é importante!

A principal estimativa de interesse é o coeficiente de regressão da variável **cyl** que indica a variação observada em Y (eficiência energética) quando a variável independente aumenta uma unidade. Como pode ser observado, esse coeficiente é de -2,8758. Ou seja, quanto maior a quantidade de cilindros do carro, em média, menor a eficiência energética. Em particular, a inclusão de um cilin-

dro adicional está associada a uma redução média de 2,8758 no valor da eficiência energética. Então veja como é intuitivo: o que essa análise tá informando é que um carro 2.0 consome, em média, mais gasolina do que um veicula 1.0, por exemplo. Sigamos!

O coeficiente de regressão (b_1) indica a variação esperada em Y quando X_1 aumenta em uma unidade

A questão do sinal é especialmente importante quando estamos diante de testes de hipótese. [Se você ainda não sabe o que é uma hipótese, veja o volume especial sobre o tema]. Não precisa ser piloto de fórmula 1 para ter uma intuição sobre o padrão de relação esperado entre a quantidade de cilindros do motor e a eficiência energética. Na sua pesquisa, a revisão da literatura vai te ajudar a formalizar essa intuição em formato de hipótese a partir de três componentes básicos: (1) um a relação esperada; (2) uma variável independente e (3) uma variável dependente. Nesse nosso exemplo, a relação esperada é negativa, a variável independente é a quantidade de cilindros e a variável dependente é a eficiência energética. E aí você poderia dizer algo mais ou menos assim: quanto maior o número de cilindros do motor, em média, menor será a eficiência energética. Tá ficando mais fácil, tá não?

Outra estimativa de interesse está na coluna $Pr(>|t|)$, que indica o valor p, também chamado de significância estatística do coeficiente de regressão. Seguindo a interpretação mais usual, um valor p inferior a 0,05 é considerado estatística significativo. “Sim, professor, mas o que significa dizer que um resultado é estatisticamente significativo?” - Ainda bem que você perguntou, já estava ficando preocupado! Veja, dizer que o nosso coeficiente foi significativo indica que podemos generalizar os resultados da amostra para a população. Ou seja, podemos afirmar, com um certo nível de segurança, que os padrões encontrados na amostra tendem a ocorrer também quando se considera os dados da população. [Iremos aprofundar o debate sobre esse tema no volume específico sobre Significância estatística, blz?]

Por fim, devemos examinar o coeficiente de determinação (R^2) que representa a proporção da variável dependente que é explicada pelo conjunto das variáveis inseridas em nosso modelo de regressão. Podemos então afirmar que a quantidade de cilindros explica cerca de 72% da variação da eficiência energética. Não é interessante? Vamos em frente.

EXEMPLO 02

```
set.seed(666)
x<-rnorm(1000,0,1)
z<-rnorm(1000,0,1)
e<-rnorm(1000,0,1)
y<- 2+ .25 * x + 1.3 * z + e
df <- as.data.frame (cbind(y,x,z))
m2 <-lm(y ~ x+z, data = df)
summary(m2)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.05797	0.03004	68.519	< 2e-16 ***
x	0.22113	0.03053	7.244	8.72e-13 ***
z	1.28379	0.03014	42.595	< 2e-16 ***

Signif. codes: 0 ‘***’ 0.001 ‘**’ 0,01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.9496 on 997 degrees of freedom

Multiple R-squared: 0.6513, Adjusted R-squared: 0.6506

F-statistic: 930.9 on 2 and 997 DF, p-value: <2.2e-16

Em nosso segundo exemplo utilizamos simulação computacional para gerar os dados. “Como assim, os dados não existem? Foram inventados? Isso tá parecendo um episódio de *Black Mirror*”. Tenha calma! A simulação é uma excelente ferramenta pois permite controlar, exatamente, os valores das variáveis, os tipos de distribuição e os padrões de relação esperados.

O código pode parecer estranho à primeira vista, mas iremos destrinchá-lo. O primeiro passo é definir a raiz da simulação a partir do comando **set.seed()**. Esse procedimento é importante para garantir exatamente os mesmos resultados, o computador vai gerar exatamente os mesmos dados na mesma ordem. Depois disso, empregamos a função **rnorm** para produzir duas variáveis normais com média zero e desvio padrão igual a um, que chamamos aqui de X e Z, respectivamente. Depois de definir as variáveis independentes, determinamos o valor de y como uma combinação linear entre X e Z, de modo que X tem peso 0,25 e Z tem peso 1,3. Esses “pesos” correspondem exatamente ao coeficiente de re-


gressão que estamos interessados em estimar. Vejamos então agora os resultados obtidos pela função `summary(m2)`.

Observe que x foi definido com peso 0,25. A estimativa encontrada pelo modelo foi de 0,22. Similarmente, Z foi definido com peso de 1,3. O valor do coeficiente informado pelo modelo foi de 1,28. Como os dados foram simulados, é fácil perceber que os valores estimados se aproximam dos parâmetros pré-determinados. Essa é uma das belezas da simulação. Tudo dá muito certo. Infelizmente, no mundo real, as coisas não funcionam dessa maneira.

Em média, quando X aumenta em uma unidade, o valor de y aumenta em 0,22 unidades, mantendo constante os valores de Z .

Similarmente, podemos dizer que a cada unidade adicional em Z , y aumenta, em média, em 1,28 unidades, mantendo constante os valores de X . Todas as variáveis foram significativas dentro dos padrões convencionais (5%). Por fim, o coeficiente de determinação (R^2) indica que cerca de 65% da variação de y pode ser explicada pelo modelo, ou seja, pela variação conjunta de X e Z .

Para saber mais sobre as potencialidades da simulação, ver o artigo dos meus amigos Fernando, Denisson e Filipe: Simulações de Monte Carlo no ensino de Ciência Política.¹



1 Se você não está totalmente confortável com o conceito de distribuição normal e ou desvio padrão, recomendo a leitura do número sobre Noções SUPER elementares de análise de dados dessa coleção.

EXEMPLO 03

Agora que você já entendeu o básico da regressão linear <o que é e para que serve> e já familiarizou com os códigos computacionais mais elementares (lm e summary), podemos seguir para um exemplo um pouco mais elaborado. Imagine aqui comigo. Depois de finalizada a leitura deste material, você foi contratada pela secretaria de segurança pública do seu estado para auxiliar na análise dos dados criminais. A planilha, organizada em formato de Excel, reúne informações detalhadas sobre as seguintes variáveis:

- a) Taxa de homicídios por 100 mil habitantes;
- b) Quantidade de policiais militares per capita;
- c) Taxa de desemprego.

O secretário quer saber se existe relação entre violencia homicida, efetivo policial e nivel de desemprego. Como dissemos no início deste documento, a regressão é a técnica adequada para avaliar o padrão de associação entre uma variável dependente e um conjunto de variáveis independentes. Pronto, vc pegou os dados, importou para dentro do R e encontrou o seguinte:

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.45730	0.25727	21.21	< 2e-16 ***
efetivo_policial	-6.01295	0.01103	-545.29	< 2e-16 ***
desemprego	2.98293	0.01561	191.04	< 2e-16 ***


Signif. codes: 0 ‘***’ 0.001 ‘**’ 0,01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.949 on 997 degrees of freedom
Multiple R-squared: 0.9971, Adjusted R-squared: 0.9971
F-statistic: 1.725e+05 on 2 and 997 DF, p-value: <2.2e-16

Vejamos agora como fica a interpretação dos resultados. Como pode ser observado, o coeficiente associado à variável “efetivo policial” é de -6,01. Ou seja, quanto maior o efetivo policial, em média, menor a taxa de homicídios. O resultado é estatisticamente significativo já que o p-valor foi menor do que 0,05, isso significa que os resultados da amostra podem ser generalizados para a população. Contrariamente, o sinal do coeficiente da variável “desemprego” foi positivo. Ou seja, quanto maior o contingente de pessoas desocupadas, em média, mais elevada a violência homicida nas localidades observadas. O coeficiente também foi estatisticamente significativo, como demonstram as colunas t value e Pr(> | t |).

Por fim, devemos avaliar o grau de explicação do nosso modelo. O coeficiente de determinação, seu amigo R^2 , foi de 0,9971. Isso significa que 99,71% da variância da variável dependente é explicada pela variação conjunta das variáveis independentes do nosso modelo. <quantidade de policiais e taxa de desemprego>. Faz sentido isso? Bem, não muito. Em Ciências Humanas, é difícil explicar a totalidade dos fenômenos de interesse. Por isso, valores de R^2 extremamente elevados servem de alerta de que algo estranho está acontecendo com nosso modelo (casos aberrantes, erro de mensuração, alta correlação entre as variáveis independentes e por aí vai). Em nosso exemplo, o ajuste foi excessivamente alto porque estamos novamente trabalhando com dados simulados. Veja o código abaixo:

```
set.seed(123)
efetivo_policial <- rnorm(1000,15,3)
desemprego <- rnorm(1000,12,2)
e <- rnorm(1000,0,1)
taxa_homi <- 5 + 3 * desemprego - 6 * efetivo_policial + e
df <- as.data.frame (cbind(taxa_homi, efetivo_policial, desemprego))
m3 <- lm(taxa_homi ~ efetivo_policial+desemprego, data = df)
summary(m3)
```





CONCLUSÃO

Neste tutorial, você aprendeu os fundamentos do modelo de regressão linear. Entendemos o que é e para que serve essa técnica, diferenciamos a regressão linear simples da regressão linear múltipla e vimos os códigos computacionais para implementar essa técnica estatística no R.

Discutimos ainda os principais pressupostos do modelo linear de regressão, revisamos as potencialidades e limitações do coeficiente de determinação e falamos sobre alguns problemas que podem afetar a nossa análise, como a presença de outliers na amostra.

Pronto. Agora você já está em condições de consumir outros materiais mais detalhados sobre o tema. Dá uma olhada nas recomendações de leitura e nas dicas de recursos pedagógicos ao final do documento.

Outros números da coleção potencialmente úteis: Noções SUPER elementares de Análise de Dados, Pressupostos da Regressão Linear, Análise de Resíduos, Outliers, R^2 , Regressão Logística e Regressão com dados de contagem.

Até a próxima!



Para dar aquele PUMP!



- Chein, F., 2019. Introdução aos modelos de regressão linear: um passo inicial para compreensão da econometria como uma ferramenta de avaliação de políticas públicas.
[Introdução interessante a partir do Stata. Puxa um pouco na matemática, mas em algum momento isso iria acontecer]
- Field, A., Miles, J. and Field, Z., 2012. Discovering statistics using R. Sage publications.
[Pode comprar sem medo!]
- Figueiredo Filho, D., Nunes, F., da Rocha, E.C., Santos, M.L., Batista, M. and Júnior, J.A.S., 2011. O que fazer e o que não fazer com a regressão: pressupostos e aplicações do modelo linear de Mínimos Quadrados Ordinários (MQO). Revista Política Hoje, 20(1).
[Artigo introdutório sobre o tema. Ideal para trabalhar em cursos básicos de estatística e análise de dados]
- Figueiredo Filho, D.B., Júnior, J.A.S. e Rocha, E.C., 2011. “<https://www.revistas.usp.br/leviathan/article/view/132282>” What is R² all about?. Leviathan (São Paulo), (3), pp.60-68.
[Essa é aquela dica que dei lá em “Perguntas e Respostas”, na pergunta 7. Leia e seja feliz!]
- Gujarati, D.N., 2022. Basic econometrics. Prentice Hall.
[Livro clássico na área de Econometria. Exige um pouco de conhecimento de matemática, mas é possível entender a maior parte dos conceitos a partir dos exemplos]
- Hair, Joseph F. “Multivariate data analysis.” (2009).
[Um dos melhores livros que voce vai ler sobre análise de dados. Vantagens: cobre a maior parte das técnicas, os conteúdos são apresentados de forma detalhada e com muitos exemplos. Desvantagem: a obra é um pouco salgada, por assim dizer, em termos de preço]
- King, Gary. “<https://www.jstor.org/stable/2111095>” How not to lie with statistics: Avoiding common mistakes in quantitative political science.” American Journal of Political Science (1986): 666-687.
[A outra recomendação da pergunta 7, do item “Perguntas e Respostas”]
- Krueger, J.S. and Lewis-Beck, M.S., 2008. Is ols dead?. The Political Methodologist, 15(2), pp.2-4.
[Artigo curtinho que examina a prevalência do modelo de regressão linear nos principais periódicos da ciência política norte-americana]
- Lewis-Beck, C. and Lewis-Beck, M., 2015. Applied regression: An introduction (Vol. 22). Sage publications.
[Recomendo fortemente. Apresenta a explicação detalhada da ferramenta a partir de exemplos intuitivos]


Outras Dicas & Recursos



Disponível em: <https://a.co/d/7U52VSG>

Uma senhora toma chá...: Como a estatística revolucionou a ciência no século XX – David Salsburg

“Um grupo de professores ingleses se reuniu no fim de 1920 para tomar chá numa tarde de verão. O assunto se voltou para uma pergunta curiosa: o gosto do chá muda de acordo com a ordem em que as ervas e o leite são colocados? Essa simples questão resultou em um estudo pioneiro na área. Nesse livro instigante, David Salsburg conta como a estatística transformou radicalmente os métodos de pesquisa na ciência, aumentando a credibilidade da investigação em diversos campos do saber, tais como a medicina, a política e a publicidade. Tudo de forma leve, partindo de quadros biográficos como o que inspirou o título dessa edição. O prefácio foi escrito pelo autor especialmente para a edição brasileira, com os desenvolvimentos da estatística no país.”



Disponível em: <https://a.co/d/5jP14QX>

O Andar do Bêbado: Como o Acaso Determina Nossas Vidas – Leonard Mlodinow

“Livro escrito por Leonard Mlodinow que explora o papel do acaso e da aleatoriedade em diversos aspectos da vida cotidiana. O autor utiliza conceitos da teoria das probabilidades e estatísticas para desvendar como eventos imprevisíveis moldam nossas experiências e decisões. Mlodinow aborda temas como o acaso nos processos de tomada de decisão, as limitações da previsão e a influência do aleatório em situações que aparentemente seguem padrões determinísticos. Por meio de exemplos práticos e histórias fascinantes, o livro fornece uma visão cativante sobre como o imprevisível e o caótico desempenham um papel fundamental em nossas vidas.”

Este livro digital foi composto nas fontes Bely Regular e Venice bold.
Cabedelo, Março de 2024


Sobre o Autor

Dalson Figueiredo é torcedor do glorioso Sport Clube Recife, campeão da Copa do Brasil de 2008. Pai de Rudá Alquete Figueiredo, Dalson atualmente é professor Associado do Departamento de Ciência Política da Universidade Federal de Pernambuco (UFPE) e Catalisador do Berkeley Initiative for Transparency in the Social Sciences (BITSS).

Em 2023, assumiu a coordenação do Programa de Pós-Graduação em Ciência Política da UFPE e, em 2022, foi pesquisador visitante na Universidade de Oxford, Reino Unido. Foi também bolsita do Summer Program in Social Science (2015-2017) e do Teaching Integrity in Empirical Research (TIER), Haverford College (2016-2017). Em 2018 foi pesquisador visitante na Universidade de Nottingham, Reino Unido.

Doutor em Ciência Política pela Universidade Federal de Pernambuco em 2012 com uma tese sobre gastos de campanha, pobreza e resultados eleitorais. Foi pesquisador visitante na Universidade de Indiana (Bloomington, 2014), na William Mitchell College of Law (Saint Paul, 2011) e na Universidade de Wisconsin (Madison, 2009). Finalizou o mestrado em Ciência Política na UFPE em 2009 com uma dissertação sobre grupos de interesse, financiamento de campanha e regulação eleitoral. Em 2005, recebeu o título de bacharel em Ciências Sociais pela UFPE, com período sanduíche na Universidade do Texas (Austin, 2003).

Atua principalmente nas áreas de métodos de pesquisa e transparência científica. Tem dois livros publicados: um sobre financiamento de campanha e outro sobre métodos quantitativos em Ciência Política.



Disponível em: <https://a.co/d/07oiAw0>



Disponível em: <https://a.co/d/hzYrQ2y>